

融合多属性邻域粒信息的随机游走异常检测模型

(西南石油大学 计算机学院, 成都 600000)

摘要: 异常检测技术已广泛应用于多个领域, 具有重要的应用价值。现有基于马尔可夫随机游走的异常检测方法虽然表现出较好检测性能, 但大多难以处理标称属性数据及混合属性数据。而现有基于邻域粗糙集的异常检测方法虽能有效处理混合属性数据, 但大多基于单一属性构建邻域关系与对象差异度量。为解决上述问题, 本文提出一种融合多属性邻域粒信息的随机游走异常检测算法 (Random walk anomaly detection model based on multi-attribute neighborhood granular information fusion, MRWOD)。算法首先基于单属性邻域熵计算单属性邻域对象差异度量, 并构建属性序列和属性集序列; 其次, 构建属性集下的邻域熵、邻域关系矩阵, 并借此得到属性集邻域对象差异度量; 进一步, 通过邻域对象差异度量构建马尔可夫状态转移矩阵; 最终, 利用迭代计算得到的平稳分布对异常点进行检测。该方法在公开数据集上与其他九种算法进行实验对比, 结果表明该方法具有良好的适应性和有效性。

关键词: 异常检测; 邻域粗糙集; 随机游走

1 引言

异常检测技术目前已广泛应用于危险驾驶行为检测^[1]、入侵检测^[2]、故障诊断^[3]和图像处理^[4]等领域, 具有重要应用价值^[5,6], 因此深入研究异常检测具有重要意义。

目前, 无监督异常检测方法已取得大量研究成果, 可根据原理和假设将其分为基于统计^[7,8]、基于距离^[9,10]、基于密度^[11,12]、基于聚类^[11,13]等方法。基于统计的方法通过识别低概率区域的样本进行异常检测。例如, 通过高斯和回归模型进行检测的参数方法^[14,15]以及利用直方图的非参数方法^[16]均为基于统计的方法。基于距离的方法则主要是通过计算对象间的距离进行检测, 例如 k 最近邻算法^[17]和基于局部距离的异常因子 (Local Distance-based Outlier Factor, LDOF) 算法^[18]便是两个经典的基于距离的异常检测算法。而基于密度的方法认为可以使用数据样本的局部密度及其邻域密度来反映数据的异常程度, 进而检测出异常点。其中 Breunig 等人^[11]提出的局部异常因子 (Outlier Factor, LOF) 算法是最具代表性算法。在 LOF 算法之后, 学者们也进一步提出新的基于密度的算法, 如基于连接性的异常因子 (Connectivity-based Outlier Factor, COF)^[19]、局部相关积分^[20]、影响异常度 (Influenced Outlierness, INFLO)^[21]、局部异常概率 (Local Outlier Probability, LoOP)^[22]以及深度密度估计框架^[23]等。基于聚类的异常检测方法主要通过判断数据样本与簇之间的关系识别异常, 比较有代表性的方法有基于簇的局部异常因子^[13]、相对异常聚类因子^[24]以及流式聚类^[25]等。上述方法虽各有侧重, 通过对象的统计特征、距离、密度及聚类结构等不同角度开展异常检测, 但多数算法仍对对象间关联关系的建模不够充分。因此, 近年来越来越多的研究开始采用图结构描述数据样本之间的关系, 并基于图模型开展相关异常检测研究。

¹收稿日期: 2026 年 7 月 9 日

马尔可夫随机游走作为基于图结构的分析方法,通过状态转移矩阵刻画样本间关系,受到广泛关注,并已广泛应用于图像分割^[26]、聚类^[27]、分类^[28]和知识获取^[29,30]等各个领域。例如, Lucas 等人^[29]将随机游走应用于知识获取任务,并比较了不同随机游走策略的知识获取性能。Lu^[31]等人为解决传统邻域方法中的欠校正和过校正问题,提出在多视图聚类任务中添加高阶随机游走。另外, Ding^[32]等人在基于消息传递的图神经网络中添加随机游走,成功扩展模型应用。而目前基于随机游走的异常检测方法主要通过构建数据样本间的相似性或相异性关系,并进一步构造状态转移矩阵,进行随机游走进而检测异常^[33-35]。例如, Moonesinghe 和 Tan^[33]首次提出基于随机游走的异常检测模型。Wang 等人^[34]也通过构造虚拟图进而模拟马尔可夫随机游走过程,最后迭代计算平稳分布并获得异常得分。Wang 和 Li^[35]构建了一种新的马尔可夫随机游走过程,并进一步进行异常检测。基于马尔可夫随机游走的异常检测方法在上述研究中均表现出较好性能,而状态转移矩阵能否准确映射对象间差异,是影响检测效果的关键。现有大多基于随机游走的异常检测方法采用基于数值运算的距离或相异性度量构建状态转移矩阵,在标称属性数据的异常检测任务上并不适用,且难以有效处理混合属性数据。因此,一种有效的改进思路是引入能够统一处理多种类型数据的数学工具。

粒计算理论近年来发展迅速,并已被应用于多个领域,如特征选择^[36]、时间序列预测^[37,38]、异常检测^[39]等。该理论是多种理论方法的集合,具体涵盖了粗糙集、模糊集、商空间及云模型等。其中,由于粗糙集理论能有效处理标称属性数据、不完备信息,其常常会被应用于各种异常检测任务中^[40-42]。例如, Jiang 等人^[43]在粗糙集理论的基础上,提出了基于序列的异常点检测方法。Shaari 等人^[44]以不可辨识矩阵模、不可辨识函数模的定义实现非约简运算,并以粗糙集异常因子作为度量指标,用于异常对象的识别与检测。Jiang 等人^[45]基于粗糙集中的信息熵,提出了一种新的异常点定义和查找算法。而后, Jiang 等人^[46]利用粗糙集理论的边界区域,提出基于边界和距离的异常点定义。Jiang 等人^[47]还提出基于近似精度的异常点检测。基于粗糙集理论, Maciá-Pérez 等人^[48]提出了一种在检测海量信息中的异常点时也能达到近似线性复杂度的异常检测算法。但基于等价关系和等价类而构建的经典粗糙集仅适合处理标称属性数据^[49],而现实中数值属性数据与混合属性数据也极为普遍,这限制了粗糙集理论的应用范围。邻域粗糙集突破了经典粗糙集仅适用于标称属性数据的限制,可统一处理标称属性与数值属性数据。人们基于邻域粗糙集理论,在异常检测领域进行了相关的探索与研究。例如, Chen 等人^[50]为解决邻域异常点检测的理解和实现问题,首次引入邻域模型作为统一框架并给出相应算法,但该算法存在参数取值敏感、参数选择困难等问题。为解决此问题,袁钟等人^[51]提出了一种新的异常检测方法作为改进策略,该方法通过邻域粗糙集的粒化特征,创造了一种邻域值差异度量方式。基于邻域粗糙集,袁钟等人^[52]进一步提出了一种基于序列的异常检测方法。袁钟等人^[53]还基于对邻域粗糙集中熵的研究,提出一种新型算法:首先通过异构距离、自适应半径构建邻域信息系统,而后通过邻域信息熵,对系统的整体不确定性进行量化测量,在此基础上构造三个渐进信息测度,最后综合计算基于邻域熵的异常因子。然而,大多现有基于邻域粗糙集理论的异常检测方法仅在单一属性上构建邻域关系与差异度量。例如,袁钟等人^[51]提出的新邻域半径构建方式,一定程度上消除了根据专家经验给定邻域半径所带来的主观性影响,但仅考虑了单个属性场景下的邻域半径构建的场景。另外,袁钟等人^[52]提出的混合曼哈顿重叠度量 (Heterogeneous Manhattan-Overlap Metric, HMOM),对于对象 $x, y \in U$ 利用它们的各个属性来构建距离度量,并对样本属性值未知的场景进行了考虑,但其依旧考虑的是基于各属性独立作用构建数据样本的距离度量。

针对现有基于马尔可夫随机游走的异常检测方法难以处理混合属性数据,以及现有基于邻域粗糙集的异常检测方法大多仅在单属性层面构建邻域关系和对象差异度量的问题,本文在马尔可夫随机游走和邻域粗糙集理论的基础之上,提出了融合多属性邻域粒信息的

随机游走异常检测模型，其中，多属性邻域粒信息由单属性邻域粒信息和属性集邻域粒信息共同构成。具体来说，本模型通过构建单属性下的邻域熵构建属性序列和属性集序列，并结合邻域关系矩阵计算单属性邻域对象差异度量。接着通过计算属性集下的邻域熵与邻域关系矩阵得到属性集邻域对象差异度量。随后，融合单属性与属性集的邻域对象差异度量，得到最终的邻域对象差异度量，该度量反映融合多属性邻域粒信息后样本间的相异性，而后以此构建邻域对象差异度量矩阵，并将归一化邻域对象差异度量得到的状态转移矩阵则用于执行马尔可夫随机游走。最终利用迭代计算得到的平稳分布来对异常点进行检测，并设计了融合多属性邻域粒信息的随机游走异常检测（Random walk anomaly detection model based on multi-attribute neighborhood granular information fusion, MRWOD）方法。该方法在公开数据上采用受试者工作特征（Receiver Operating Characteristic, ROC）曲线和曲线下面积（Area Under Curve, AUC）这两项指标，与当前的九种先进异常检测方法进行比较。

本文的主要创新点总结如下：

- (1) 提出了一种融合单属性邻域粒和属性集邻域粒信息的对象差异度量构建方法，实现样本间相异性的多粒度刻画。
- (2) 提出了一种基于邻域对象差异度量构建马尔可夫状态转移矩阵的方法。通过将基于邻域粗糙集理论得到的对象间差异映射状态转移概率，为数值属性、标称属性及混合属性数据构建统一的状态转移矩阵。

本文后续内容组织如下：第 2 节介绍预备知识，包括多属性邻域粒的构建和马尔可夫随机游走的基础；第 3 节给出异常检测方法的详细构造、算法流程、时间复杂度分析以及实例说明；第 4 节通过实验验证方法的有效性；第 5 节对全文进行总结。

2 预备知识

本节主要回顾邻域粗糙集的一些基本概念，包括邻域关系、邻域密度和邻域熵等，以及介绍马尔可夫随机游走，为后续状态转移矩阵和异常检测算法的构造提供基础。

2.1 信息系统与数据归一化

给定一个四元组 $IS = \langle U, A, V, f \rangle$ 来描述信息系统^[54]。在 IS 中，非空有限论域 $U = \{x_1, x_2, \dots, x_n\}$ 中包含了 n 个对象，此处论域代表实际问题场景中涉及到的全部对象； $A = \{a_1, a_2, \dots, a_m\}$ 为一个包含 m 个属性的非空有限属性集合； $V = \bigcup_{a \in A} V_a$ 为 A 中所有属性值域 V_a 的并； $f: U \times A \rightarrow V$ 是一个信息函数，其使得对于 $\forall x \in U$ 以及 $a \in A$ ，有 $f(x, a) \in V_a$ 。若将属性集合 A 划分为两个部分，其中一部分为条件属性集 $C = \{c_1, c_2, \dots, c_k\}$ ，另一部分为决策属性集 D ，且 $C \cap D = \emptyset$ 时，可将信息系统称为决策表或者决策系统，将其记为 $DS = (U, C \cup D, V, f)$ 。

为了在实施相关算法前对数值属性数据进行归一化处理，采用最小-最大归一化方法，其计算公式如下：

$$F(f(x_i, c_j)) = \frac{f(x_i, c_j) - \min_{c_j}}{\max_{c_j} - \min_{c_j}}, \quad (1)$$

其中， $\max_{c_j}$ 和 $\min_{c_j}$ 分别是属性 c_j 之上的最大值和最小值。

通过式 (1) 对数值属性数据进行归一化处理, 可以将属性的取值区间转为 $[0, 1]$ 的范围, 便于后续处理。归一化算法仅用于处理数值属性数据, 不对标称属性数据做处理。

2.2 多属性混合距离与自适应邻域半径

基于袁钟等人 [52] 提出的混合曼哈顿重叠度量 (HMOM), 本文进一步地考虑对象在某个属性子集 B 上的距离度量, 并根据 B 中可能包含的数值、标称或混合属性进行距离度量的计算, 从而得以构建多属性集下的距离度量。下面将给出与 HMOM 距离构造方式相仿的多属性混合曼哈顿重叠度量 (Multi-attribute Heterogeneous Manhattan-Overlap Metric, MHMOM) 的定义。

对象 $x, y \in U$ 在属性子集 $B = \{c_1, c_2, \dots, c_k\}, 1 \leq k \leq m$ 上的多属性混合曼哈顿重叠度量为:

$$MHMOM_B(x, y) = \frac{\sum_{j=1}^k d_{c_j}(x, y)}{k}, \quad (2)$$

$$\text{其中, } d_{c_j}(x, y) = \begin{cases} 0, & \text{若 } c_j \text{ 是标称属性且 } f(x, c_j) = f(y, c_j); \\ 1, & \text{若 } c_j \text{ 是标称属性且 } f(x, c_j) \neq f(y, c_j); \\ |f(x, c_j) - f(y, c_j)|, & \text{若 } c_j \text{ 是数值属性。} \end{cases}$$

当属性子集 B 中仅包含一个元素 (即 $k = 1$) 时, $MHMOM$ 的计算取决于单个元素的属性类别。若属性为标称属性, 则通过判定对象间对应的标称属性是否相等来计算距离。若属性为数值属性, 则通过计算对象间的曼哈顿距离来计算距离。而当属性子集中的元素数量多于一个 (即 $k \geq 2$) 时, 对象间的距离则通过将其中各个元素的距离相加后求平均来取得, 以此来衡量多属性下的 $MHMOM$ 。因此, 基于多属性混合曼哈顿重叠度量, 可以计算得到对象 $x, y \in U$ 在属性子集 B 上的距离度量, 且同时适用于标称与数值属性数据。

另外, 在文献 [51] 中提出一种新的邻域半径构建方式的基础上, 本文提出多属性邻域半径, 为多属性下的邻域信息的构建奠定基础。具体而言, 本文将对象 $x \in U$ 在属性子集 B 上的多属性邻域半径设为:

$$\varepsilon_B = \frac{\sum_{j=1}^k g(c_j)}{k}, \quad (3)$$

$$\text{其中, } g(c_j) = \begin{cases} std(c_j)/\lambda, & \text{若 } c_j \text{ 是数值属性;} \\ 0, & \text{若 } c_j \text{ 为标称属性。} \end{cases} \quad \text{std}(c_j) \text{ 为属性 } c_j \text{ 的标准差, } \lambda \text{ 为半径调}$$

节因子。

当属性子集 B 中的元素均为标称属性时, 由式 (3) 可知, $\varepsilon_B = 0$ 。而当 $k = 1$ 时, 混合多属性邻域半径 ε_B 的计算公式退化为单属性邻域半径计算公式。

2.3 邻域、邻域密度与邻域熵

邻域关系矩阵用于明确表示在特定邻域信息系统中各个对象之间是否存在相关性。构建邻域关系矩阵需先计算出邻域与相应的邻域关系。

式 (2) 与式 (3) 中均考虑了需要对混合多属性信息进行融合的场景, 定义了多属性视角下的距离度量与邻域半径。为更为明确地给出邻域及邻域关系的具体表示形式, 文章在

此对其做了更明确的限定。对象 $x \in U$ 在某个属性子集 B 上的邻域为：

$$\sigma_B^\varepsilon(x) = \{y \mid MHMOM_B(x, y) \leq \varepsilon_B, y \in U\}。 \quad (4)$$

式 (4) 定义了某个对象 x 在属性子集 B 上的邻域。而借助邻域的概念，进一步地可对属性子集 B 上的邻域关系进行定义。

给定对象 $x, y \in U$ ，二者在某个属性子集 B 的邻域关系为：

$$\delta_B(x, y) = \begin{cases} 0, y \notin \sigma_B^\varepsilon(x); \\ 1, y \in \sigma_B^\varepsilon(x)。 \end{cases} \quad (5)$$

进一步，通过邻域与邻域关系，文章将给出邻域关系矩阵的相关解释。给定论域 $U = \{x_1, x_2, \dots, x_n\}$ ，某个属性子集 B 上的邻域关系矩阵为：

$$\mathbf{M}(\sigma_B^\varepsilon) = \begin{bmatrix} \delta_B(x_1, x_1) & \cdots & \delta_B(x_1, x_n) \\ \vdots & \ddots & \vdots \\ \delta_B(x_n, x_1) & \cdots & \delta_B(x_n, x_n) \end{bmatrix}。 \quad (6)$$

邻域关系矩阵描述了论域 U 中的对象 $\{x_1, x_2, \dots, x_n\}$ ，在某个属性子集 B 上彼此之间根据给定的邻域关系是否相关。当一对对象邻域关系对应的值为 1，代表二者在给定的邻域关系下相关。当一对对象邻域关系对应的值为 0，代表二者在给定的邻域关系下不相关。

利用由式 (6) 得到的邻域关系矩阵，可通过统计每个对象的邻居数目得到邻域密度。给定对象 $x_i \in U$ ，其在属性子集 B 上的邻域密度 (Neighborhood Density, ND) 为：

$$ND_B(x_i) = \frac{\sum_{j=1}^n \delta_B(x_i, x_j)}{|U|}。 \quad (7)$$

由式 (7) 可知，当对象 x_i 在属性子集 B 上相关联的邻居越少，其对应的邻域密度越小。

考虑到各属性对于对象的异常程度的影响并不相同，文章参考了 Hu 等人 [55] 引入的邻域熵，并以此来对对象的不确定程度进行度量。对于属性子集 B 上的邻域熵 (Neighborhood Entropy, NE) 为：

$$NE(B) = -\frac{1}{|U|} \sum_{x_i \in U} \log_2 \frac{\sum_{j=1}^n \delta_B(x_i, x_j)}{|U|}。 \quad (8)$$

根据式 (8) 可知，邻域熵越大，则其值域的分布越无序，也意味着不确定性越大。

2.4 基于邻域熵的属性集序列生成

为了从多属性的视角构建相关的度量，需要以相对合理的方式构建相应的属性集合。为此，本文将先利用邻域熵排序获得属性序列，再进一步构造属性集序列，从而获得相应的属性集合。首先，给出属性序列 S 的定义为：

$$S = \langle c'_1, c'_2, \dots, c'_m \rangle， \quad (9)$$

其中， $NE(c'_k) \leq NE(c'_{k+1})$ ， $1 \leq k < m$ 。

进一步, 由条件属性集 C 开始, 依次去除其中单属性邻域熵最大的属性, 将剩下的属性归为一个集合, 放入一个属性集序列中。如此操作直至属性集中仅剩单个属性。如下, 属性集序列 QS 为:

$$QS = \langle Q_1, Q_2, \dots, Q_m \rangle, \quad (10)$$

其中, $Q_k \subseteq C$, $Q_1 = C$, $Q_m = \{c'_1\}$, $Q_{k+1} = Q_k - \{c'_{m-k+1}\}$, $1 \leq k < m$ 。

2.5 马尔可夫随机游走

给定一个概率空间 $(\Omega, \mathcal{F}, PR)$, 其中 Ω 、 $\mathcal{F}$ 及 PR 分别表示样本空间、随机事件集合及概率。给定一个参数集 T , 若 $X = \{X_t \mid t \in T\}$ 是 $(\Omega, \mathcal{F}, PR)$ 上的依赖于参数集 T 的一族随机变量, 则称 X 是随机过程。

给定一个随机过程 $X = \{X_t \mid t \in \{0, 1, \dots\}\}$ 。当 $t > 1$ 时, 如果 $X(t)$ 仅依赖于 $X(t-1)$, 而不依赖于在 t 时刻之前更早时刻的随机变量 $\{X_0, X_1, \dots, X_{t-2}\}$, 则 X 被称为离散时间中的马尔可夫链。此时, 具备如下关系:

$$p(X_t \mid X_0, X_1, \dots, X_{t-1}) = p(X_t \mid X_{t-1}), \quad (11)$$

其中, 状态转移概率 $p(X_t \mid X_{t-1})$ 的含义为在 $t-1$ 时刻的状态 X_{t-1} 下, 下一时刻状态转移 X_t 的概率。

对于包含 n 个状态的马尔可夫链, 可用状态转移矩阵 $\mathbf{P}$ 表示这一条件概率值:

$$\mathbf{P} = \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{nn} \end{bmatrix}. \quad (12)$$

通过使用状态转移矩阵迭代计算概率分布, 可求得随机游走 t 次后稳定下来的各个状态的概率。马尔可夫链的状态分布由初始分布和状态转移概率分布决定^[56]。平稳分布指的是当链在经过足够长的时间后, 即通过状态转移矩阵经过足够次数的迭代后, 状态分布不再随时间变化, 达到稳定的状态时的分布。也就是说, 对于具有状态转移矩阵 $\mathbf{P}$ 的马尔可夫链, 若存在概率分布 $\boldsymbol{\nu}$ 满足

$$\boldsymbol{\nu} = \boldsymbol{\nu} \mathbf{P}, \quad (13)$$

则该分布 $\boldsymbol{\nu}$ 被称为平稳分布。其含义是: 若当前时刻的状态服从该分布, 则在转移到下一时刻后, 该状态仍服从该分布。如果状态空间有 n 个状态, 那么平稳分布向量是一个长度为 n 的概率向量 $\boldsymbol{\nu} = [\nu_1, \nu_2, \dots, \nu_n]$, 其中 ν_i 表示平稳分布中第 i 个状态的概率。

3 提出算法

预备知识给出了融合多属性邻域粒信息及其邻域密度、邻域熵的计算方法, 以及马尔可夫随机游走的概念与状态转移矩阵的构造。本节将给出融合多属性邻域粒信息的状态转移矩阵构造方法、随机游走过程及完整的检测算法。接下来开始对状态转移矩阵的构建和随机游走过程进行介绍。

3.1 邻域对象差异度量

为了有效地构建邻域粗糙集中单属性下的对象差异度量，文章在此对单属性邻域对象差异度量 (Single Attribute Neighborhood Object Difference Measurement, SNODM) 进行计算。SNODM 的定义如下：

定义 1 (单属性邻域对象差异度量) 给定 $x, y \in U$, $c_j \in C$, 则对象 x 与 y 的单属性邻域对象差异度量定义为：

$$SNODM(x, y) = \sum_{c_j \in C} SW(c_j) (|ND_{c_j}(x) - ND_{c_j}(y)|), \quad (14)$$

其中, $SW(c_j) = \frac{NE(\{c_j\})}{\sum_{c_l \in C} (NE(\{c_l\}))}$, 为属性 c_j 的单属性邻域熵权重 (Single Attribute Neighborhood Entropy Weight, SW)。

单属性邻域对象差异度量刻画了论域 U 中任意两个对象 x, y 在所有单属性 c_j 上的差异度量, 并通过权重因子对相应的属性进行加权, 从而放大更重要的属性下的单属性对象差异度量, 降低不重要的属性下的单属性对象差异度量。

而为了有效地构建邻域粗糙集中属性集视角下的对象差异度量, 本文在此对属性集邻域对象差异度量 (Attribute Set Neighborhood Object Difference Measurement, ANODM) 进行计算。ANODM 的具体定义如下：

定义 2 (属性集邻域对象差异度量) 给定 $x, y \in U$, $Q_j \in QS$, 则对象 x 与对象 y 的属性集邻域对象差异度量定义为：

$$ANODM(x, y) = \sum_{Q_j \in QS} AW(Q_j) (|ND_{Q_j}(x) - ND_{Q_j}(y)|), \quad (15)$$

其中, $AW(Q_j) = \frac{NE(Q_j)}{\sum_{Q_l \in QS} NE(Q_l)}$, 为属性集 Q_j 的属性集邻域熵权重 (Attribute Set Neighborhood Entropy Weight, AW)。

属性集邻域对象差异度量刻画了论域 U 中任意两个对象 x, y 在所有属性集 Q_j 上的差异度量, 并通过权重因子对相应的属性集进行加权, 从而放大更重要的属性集下的属性集对象差异度量, 降低不重要的属性集下的属性集对象差异度量。

在式 (14) 式 (15) 中, 已得到了单属性邻域对象差异度量与属性集邻域对象差异度量。在此, 本文将通过将单属性邻域对象差异度量与属性集邻域对象差异度量相结合, 融合多属性的邻域粒信息, 并最终得到对象 x 与对象 y 的邻域对象差异度量 (Neighborhood Object Difference Measurement, NODM)。

定义 3 (邻域对象差异度量) 给定 $x, y \in U$, 则对象 x 与对象 y 的邻域对象差异度量定义为：

$$NODM(x, y) = SNODM(x, y) + ANODM(x, y). \quad (16)$$

3.2 状态转移矩阵的构造与随机游走

在邻域对象差异度量的基础上, 本文进一步得到一个邻域对象差异度量矩阵 $DM = (NODM(x_i, x_j))_{n \times n}$ 。通过将矩阵 DM 的各行归一化, 可以得到状态转移矩阵 P 。其相应的计算公式如下：

$$\mathbf{P} = \mathbf{Z}^{-1} \times \mathbf{DM}, \quad (17)$$

其中, 矩阵 $\mathbf{Z} = \text{diag}(z_1, z_2, \dots, z_n)$ 是一个对角矩阵, 其对角元为矩阵 $\mathbf{DM}$ 相应行元素之和。通过式 (17) 得到的状态转移矩阵 $\mathbf{P}$, 其各行之和为 1, 这是马尔可夫链的一个基本特征。

接下来, 概率分布应从初始状态出发, 使用 $\mathbf{P}$ 迭代使其趋于平稳分布 (式 (13))。然而, 为避免链陷入吸收态并保证唯一平稳分布的存在, 需要保证 $\mathbf{P}$ 同时是可积的和无环的。这里, 本文采用 Moonesinghe 等人^[33] 的策略, 在每次迭代中保持一个低概率值来重启随机游走。因此, 式 (13) 可以修改为:

$$\boldsymbol{\nu}^{(t)} = d \cdot \mathbf{I} + (1 - d)\boldsymbol{\nu}^{(t-1)}\mathbf{P}, \quad (18)$$

其中, d 是一个阻尼因子, 表示以概率 d 重启到均匀分布, 以概率 $1 - d$ 按状态转移矩阵继续游走, 本节中将 d 的值设为 0.1。 $\mathbf{I} = \left[\frac{1}{|\mathcal{U}|}, \frac{1}{|\mathcal{U}|}, \dots, \frac{1}{|\mathcal{U}|} \right]$, 为单位行向量, 满足 $|\mathbf{I}| = 1$ 。

由定义 3 可知, 任意两个对象的差异越大, 则邻域对象差异度量越大。因此在上述状态转移矩阵中, 差异越大的两个对象间的访问概率越高。换言之, 异常对象相比于其余对象, 更容易在随机游走中获得较高访问概率。在得到平稳分布后, 为了更好比较不同数据集上所得到的各个样本的异常程度, 采用式 (1) 中的最小-最大归一化算法来对得到的平稳分布进行归一化处理。其具体解释如下: 在给定平稳分布 $\boldsymbol{\nu}$, 任意对象 $x_i \in \mathcal{U}$ 后, 对象 x_i 对应的马尔可夫随机游走异常因子为:

$$MRWOD(x_i) = \frac{\nu_i - \min(\boldsymbol{\nu})}{\max(\boldsymbol{\nu}) - \min(\boldsymbol{\nu})}. \quad (19)$$

对于给定的阈值 μ , 若 $MRWOD(x_i) > \mu$, 则称对象 x_i 为融合多属性邻域粒信息的马尔可夫随机游走异常检测算法下的异常点。

3.3 MRWOD 算法与时间复杂度

算法 1 中, 步骤 1 初始化异常因子 $OS = \emptyset$ 。步骤 2-6 通过 “for” 循环遍历各个属性, 频度为 m , 每个 “for” 循环内均计算单属性下的邻域关系矩阵, 并以此进一步计算单属性邻域密度、单属性邻域熵, 频度为 n^2 , 总体频度为 $m \times n^2$ 。步骤 7 计算单属性邻域对象差异度量, 频度为 $m \times n^2$ 。构建单属性邻域对象差异度量的总时间复杂度为 $m \times n^2$ 。步骤 8 通过单属性邻域熵将属性进行排列, 频度为 m 。步骤 9 通过属性序列构建多属性下的序列, 频度为 m 。步骤 10-14 通过 “for” 循环遍历各个属性集, 频度为 m , 接着计算各属性集下的邻域关系矩阵, 并通过多属性邻域关系矩阵计算多属性邻域密度、多属性邻域熵, 频度为 n^2 , 总体频度为 $m \times n^2$ 。步骤 15 计算属性集邻域对象差异度量, 频度为 $m \times n^2$ 。步骤 16 计算状态转移矩阵 $\mathbf{P}$ 。由此可得, 最坏情况下, 构建属性集邻域对象差异度量的总时间复杂度为 $m \times n^2$ 。步骤 17-20 通过 “while” 循环, 得到平稳分布。步骤 21-26 中, 通过 “for” 循环, 计算每个样本的马尔可夫随机游走异常因子, 然后采用 “if” 判断马尔可夫随机游走异常因子是否大于阈值, 若大于阈值, 则将对应该样本点加入异常点集合, 频度为 n 。基于上述分析, 算法 1 的时间复杂度为 $O(mn^2)$ 。

算法 1 MRWOD 算法

输入: 信息系统 $IS = (U, A, V, f)$, λ , 阈值 μ , 阻尼因子 $d = 0.1$, $t = 1$, 其中, $|U| = n$, $|A| = m$

输出: 异常点集合 OS

```
1:  $OS \leftarrow \emptyset$ ;
2: for  $i = 1$  to  $m$  do
3:   计算单属性邻域关系矩阵  $M(n_{c_i}^\varepsilon)$ ;
4:   计算单属性邻域密度  $ND_{c_i}$ ;
5:   计算单属性邻域熵  $NE(c_i)$ ;
6: end for
7: 计算单属性邻域对象差异度量  $SNODM$ ;
8: 确定属性序列  $S = \langle c'_1, c'_2, \dots, c'_m \rangle$ ;
9: 构建属性集序列  $QS = \langle Q_1, Q_2, \dots, Q_m \rangle$ ;
10: for  $Q_j \in QS$  do
11:   计算多属性邻域关系矩阵  $M(n_{Q_j}^\varepsilon)$ ;
12:   计算多属性邻域密度  $ND_{Q_j}$ ;
13:   计算多属性邻域熵  $NE(Q_j)$ ;
14: end for
15: 计算属性集邻域对象差异度量  $ANODM$ ;
16: 计算状态转移矩阵  $P$ ;
17: while  $\|\nu^{(t)} - \nu^{(t-1)}\|_1 \geq 10^{-3}$  do
18:    $\nu^{(t)} = d \cdot I + (1 - d)\nu^{(t-1)}P$ ;
19:    $t++$ ;
20: end while
21: for  $i = 1$  to  $n$  do
22:   计算马尔可夫随机游走异常因子  $MRWOD(x_i)$ ;
23:   if  $MRWOD(x_i) > \mu$  then
24:      $OS = OS \cup \{x_i\}$ ;
25:   end if
26: end for
27: return  $OS$ 
```

3.4 示例说明

为了对前述内容的算法做更进一步的说明, 本节在给定信息系统下给出了相应的计算过程。

如表 1 所示, 竖线左侧为一个初始的未经处理的信息系统。竖线右侧为经过式 (1) 进行处理后的信息系统。在接下来的流程当中, 将以竖线右侧所示的信息系统作为初始的输入进行流程的展示。

在表 1 所示的信息系统当中, U 表示各个对象, c_1 列中为标称属性数据, 其对应的单属性邻域半径为 $\varepsilon_{c_1} = 0$, c_2 与 c_3 中为数值型属性数据, 各自的标准差为 $std(c_2) \approx 0.3492$ 和 $std(c_3) \approx 0.3727$ 。邻域半径调节因子 $\lambda = 1$, 由式 (3) 可得在 c_2 和 c_3 当中, $\varepsilon_{c_2} \approx 0.3492$, $\varepsilon_{c_3} \approx 0.3727$ 。经过计算, $\forall c_t \in C$ 的单属性邻域关系矩阵如下:

表 1 初始和标准化信息系统

表 1 Initial and standardized information system

U	c_1	c_2	c_3	c_1	c_2	c_3
x_1	c	10	0.7	c	1.0000	1.0000
x_2	b	6	0.3	b	0.5000	0.0000
x_3	d	2	0.5000	d	0.0000	0.5000
x_4	b	3	0.3	b	0.1250	0.0000
x_5	b	7	0.4	b	0.6250	0.2500
x_6	d	3	0.6	d	0.1250	0.7500

$$M(n_{c_1}^\varepsilon) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \end{bmatrix}, \quad M(n_{c_2}^\varepsilon) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 1 \end{bmatrix},$$

$$M(n_{c_3}^\varepsilon) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 \end{bmatrix}.$$

下面给出相关计算过程，主要包含如下步骤：

(1) 根据式 (8) 计算单属性下的邻域熵如下：

$$\begin{aligned} NE(c_1) &= -\frac{1}{|U|} \sum_{x \in U} \log_2 \frac{\sum_{j=1}^n \delta_{c_1}(x_i, x_j)}{|U|} \\ &= -\frac{1}{6} (\log_2 \frac{1}{6} + \log_2 \frac{3}{6} + \log_2 \frac{2}{6} + \log_2 \frac{3}{6} + \log_2 \frac{3}{6} + \log_2 \frac{2}{6}) \\ &\approx 1.4591, \end{aligned}$$

同理可得， $NE(c_2) \approx 1.4591$ ， $NE(c_3) \approx 1.0283$ 。

(2) 根据式 (7) 计算单属性下的邻域密度如下:

$$\begin{aligned}
ND_{c_1}(x_1) &= \frac{1}{6} \approx 0.1667, \quad ND_{c_2}(x_1) = \frac{1}{6} \approx 0.1667, \quad ND_{c_3}(x_1) = \frac{2}{6} \approx 0.3333, \\
ND_{c_1}(x_2) &= 0.5000, \quad ND_{c_2}(x_2) \approx 0.3333, \quad ND_{c_3}(x_2) = 0.5000, \\
ND_{c_1}(x_3) &\approx 0.3333, \quad ND_{c_2}(x_3) = 0.5000, \quad ND_{c_3}(x_3) = 0.5000, \\
ND_{c_1}(x_4) &= 0.5000, \quad ND_{c_2}(x_4) = 0.5000, \quad ND_{c_3}(x_4) \approx 0.5000, \\
ND_{c_1}(x_5) &= 0.5000, \quad ND_{c_2}(x_5) = 0.3333, \quad ND_{c_3}(x_5) = 0.6667, \\
ND_{c_1}(x_6) &\approx 0.3333, \quad ND_{c_2}(x_6) = 0.5000, \quad ND_{c_3}(x_6) \approx 0.5000.
\end{aligned}$$

(3) 根据定义式 (14) 计算样本的单属性邻域对象差异度量如下:

$$SW(c_1) = \frac{1.4591}{1.4591 + 1.4591 + 1.0283} \approx 0.3697,$$

同理可得: $SW(c_2) \approx 0.3697$, $SW(c_3) \approx 0.2606$ 。

$$\begin{aligned}
SNODM(x_1, x_2) &= SNODM(x_2, x_1) \\
&= \sum_{c_j \in C} SW(c_j)(ND_{c_j}(x_1) - ND_{c_j}(x_2))^2 \\
&= 0.3697 \times (|0.1667 - 0.5000|) + 0.3697 \times (|0.1667 - 0.3333|) + \\
&\quad 0.2606 \times (|0.3333 - 0.5000|) \\
&\approx 0.2283,
\end{aligned}$$

同理可得: $SNODM(x_1, x_3) \approx 0.2283$, $SNODM(x_1, x_4) \approx 0.2899$, $SNODM(x_1, x_5) \approx 0.2717$, $SNODM(x_1, x_6) \approx 0.2283$, $SNODM(x_2, x_3) \approx 0.1232$, $SNODM(x_2, x_4) \approx 0.0616$, $SNODM(x_2, x_5) \approx 0.0434$, $SNODM(x_2, x_6) \approx 0.1232$, $SNODM(x_3, x_4) \approx 0.0616$, $SNODM(x_3, x_5) \approx 0.1667$, $SNODM(x_3, x_6) \approx 0.0000$, $SNODM(x_4, x_5) \approx 0.1050$, $SNODM(x_4, x_6) \approx 0.0616$, $SNODM(x_5, x_6) \approx 0.1667$ 。

(4) 根据式 (9) 可将属性根据单属性邻域熵升序排序如下:

$$S = \langle c'_1, c'_2, c'_3 \rangle = \langle c_3, c_1, c_2 \rangle。$$

(5) 根据式 (10) 可获得如下属性集序列:

$$QS = \langle Q_1, Q_2, Q_3 \rangle, \text{ 其中, } Q_1 = \{c_3, c_1, c_2\}, \quad Q_2 = \{c_3, c_1\}, \quad Q_3 = \{c_3\}。$$

(6) 根据式 (2) 及式 (3) 计算各属性集下的 $MHMOM$ 距离及邻域半径:

$$\begin{aligned}
MHMOM_{Q_1}(x_1, x_2) &= MHMOM_{Q_1}(x_2, x_1) = \frac{\sum_{j=1}^3 d_{c_j}(x_1, x_2)}{3} = \frac{1.0000 + 0.5000 + 1.0000}{3} \\
&\approx 0.8333,
\end{aligned}$$

同理, 计算可得属性集 Q_1, Q_2, Q_3 下各对象间的 $MHMOM$ 距离, 属性集 Q_i 下各对象间

的 $MHMOM$ 距离可用矩阵 $MHMOM_{Q_i}$ 进行表示:

$$\begin{aligned}
 MHMOM_{Q_1} &= \begin{bmatrix} 0.0000 & 0.8333 & 0.8333 & 0.9583 & 0.7083 & 0.7083 \\ 0.8333 & 0.0000 & 0.6667 & 0.1250 & 0.1250 & 0.7083 \\ 0.8333 & 0.6667 & 0.0000 & 0.5417 & 0.6250 & 0.1250 \\ 0.9583 & 0.1250 & 0.5417 & 0.0000 & 0.2500 & 0.5833 \\ 0.7083 & 0.1250 & 0.6250 & 0.2500 & 0.0000 & 0.6667 \\ 0.7083 & 0.7083 & 0.1250 & 0.5833 & 0.6667 & 0.0000 \end{bmatrix}, \\
 MHMOM_{Q_2} &= \begin{bmatrix} 0.0000 & 0.7500 & 0.7500 & 0.9375 & 0.5625 & 0.5625 \\ 0.7500 & 0.0000 & 0.5000 & 0.1875 & 0.1875 & 0.5625 \\ 0.7500 & 0.5000 & 0.0000 & 0.3125 & 0.4375 & 0.1875 \\ 0.9375 & 0.1875 & 0.3125 & 0.0000 & 0.3750 & 0.3750 \\ 0.5625 & 0.1875 & 0.4375 & 0.3750 & 0.0000 & 0.5000 \\ 0.5625 & 0.5625 & 0.1875 & 0.3750 & 0.5000 & 0.0000 \end{bmatrix}, \\
 MHMOM_{Q_3} &= \begin{bmatrix} 0.0000 & 1.0000 & 0.5000 & 1.0000 & 0.7500 & 0.2500 \\ 1.0000 & 0.0000 & 0.5000 & 0.0000 & 0.2500 & 0.7500 \\ 0.5000 & 0.5000 & 0.0000 & 0.5000 & 0.2500 & 0.2500 \\ 1.0000 & 0.0000 & 0.5000 & 0.0000 & 0.2500 & 0.7500 \\ 0.7500 & 0.2500 & 0.2500 & 0.2500 & 0.0000 & 0.5000 \\ 0.2500 & 0.7500 & 0.2500 & 0.7500 & 0.5000 & 0.0000 \end{bmatrix}.
 \end{aligned}$$

$$\varepsilon_{Q_1} = \frac{\varepsilon_{c_2} + \varepsilon_{c_3} + \varepsilon_{c_1}}{3} = \frac{0.3727 + 0.3492 + 0}{3} \approx 0.2406,$$

同理, $\varepsilon_{Q_2} \approx 0.1865$, $\varepsilon_{Q_3} = 0.3727$ 。

(7) 根据定义式 (6) 计算 $\forall Q_t \in QS$ 的多属性邻域关系矩阵如下:

$$M(n_{Q_1}^\varepsilon) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \end{bmatrix}, \quad M(n_{Q_2}^\varepsilon) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \end{bmatrix},$$

$$M(n_{Q_3}^\varepsilon) = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 \end{bmatrix}.$$

(8) 根据式 (8) 计算多属性下的邻域熵如下:

$$NE(Q_1) = -\frac{1}{|U|} \sum_{x \in U} \log_2 \frac{\sum_{j=1}^n \delta_{Q_1}(x_i, x_j)}{|U|} \approx 1.6541,$$

同理可得, $NE(Q_2) \approx 1.4591$, $NE(Q_3) \approx 1.0283$ 。

(9) 根据式 (7) 计算多属性下的邻域密度如下:

$$ND_{Q_1}(x_1) = \frac{1}{6} \approx 0.1667, \quad ND_{Q_2}(x_1) = \frac{1}{6} \approx 0.1667, \quad ND_{Q_3}(x_1) = \frac{2}{6} \approx 0.3333,$$

$$ND_{Q_1}(x_2) = 0.5000, \quad ND_{Q_2}(x_2) = 0.5000, \quad ND_{Q_3}(x_2) \approx 0.5000,$$

$$ND_{Q_1}(x_3) \approx 0.3333, \quad ND_{Q_2}(x_3) \approx 0.3333, \quad ND_{Q_3}(x_3) = 0.5000,$$

$$ND_{Q_1}(x_4) \approx 0.3333, \quad ND_{Q_2}(x_4) \approx 0.5000, \quad ND_{Q_3}(x_4) = 0.5000,$$

$$ND_{Q_1}(x_5) \approx 0.3333, \quad ND_{Q_2}(x_5) \approx 0.5000, \quad ND_{Q_3}(x_5) = 0.6667,$$

$$ND_{Q_1}(x_6) \approx 0.3333, \quad ND_{Q_2}(x_6) \approx 0.3333, \quad ND_{Q_3}(x_6) = 0.5000.$$

(10) 根据式 (15) 计算属性集邻域对象差异度量如下:

$$AW(Q_1) = \frac{1.6541}{1.6541 + 1.4591 + 1.0283} \approx 0.3994.$$

同理可得: $AW(Q_2) \approx 0.3523$, $AW(Q_3) \approx 0.2483$ 。

$$\begin{aligned} ANODM(x_1, x_2) &= ANODM(x_2, x_1) = \sum_{Q_j \in QS} AW(Q_j)(ND_{Q_j}(x_1) - ND_{Q_j}(x_2)) \\ &= 0.3994 \times (|0.1667 - 0.5000|) + 0.3523 \times (|0.1667 - 0.5000|) + \\ &\quad 0.2483 \times (|0.3333 - 0.5000|) \\ &\approx 0.2919, \end{aligned}$$

同理可得: $ANODM(x_1, x_3) \approx 0.1667$, $ANODM(x_1, x_4) \approx 0.2254$, $ANODM(x_1, x_5) \approx 0.2667$, $ANODM(x_1, x_6) \approx 0.1667$, $ANODM(x_2, x_3) \approx 0.1253$, $ANODM(x_2, x_4) \approx 0.0666$, $ANODM(x_2, x_5) \approx 0.1080$, $ANODM(x_2, x_6) \approx 0.1253$, $ANODM(x_3, x_4) \approx 0.0587$, $ANODM(x_3, x_5) \approx 0.1001$, $ANODM(x_3, x_6) \approx 0.0000$, $ANODM(x_4, x_5) \approx 0.0414$, $ANODM(x_4, x_6) \approx 0.0587$, $ANODM(x_5, x_6) \approx 0.1001$ 。

(11) 根据式 (16) 及式 (17) 计算状态转移矩阵 $\mathbf{P}$ 如下:

$$\mathbf{P} = \begin{bmatrix} 0.0000 & 0.2201 & 0.1671 & 0.2180 & 0.2278 & 0.1671 \\ 0.4012 & 0.0000 & 0.1916 & 0.0988 & 0.1167 & 0.1916 \\ 0.3832 & 0.2411 & 0.0000 & 0.1168 & 0.2589 & 0.0000 \\ 0.5000 & 0.1244 & 0.1168 & 0.0000 & 0.1421 & 0.1168 \\ 0.3931 & 0.1105 & 0.1947 & 0.1069 & 0.0000 & 0.1947 \\ 0.3832 & 0.2411 & 0.0000 & 0.1168 & 0.2589 & 0.0000 \end{bmatrix}.$$

同时, 通过式 (18) 迭代计算得到平稳分布:

$$\nu \approx [0.2910, 0.1597, 0.1269, 0.1269, 0.1687, 0.1269].$$

(12) 最后, 根据最大-最小归一化计算各个样本的马尔可夫随机游走异常因子如下:

$$MRWOD(x_1) = \frac{0.2910 - 0.1269}{0.2910 - 0.1269} = 1,$$

同理可得, $MRWOD(x_2) \approx 0.1999$, $MRWOD(x_3) = 0.0000$, $MRWOD(x_4) \approx 0.0000$, $MRWOD(x_5) \approx 0.2547$, $MRWOD(x_6) = 0.0000$.

假设给定的阈值 $\mu = 0.8000$, 则仅有 $MRWOD(x_1) = 1 > \mu$, 故 x_1 是 U 中的一个基于 MRWOD 算法的异常点, 而其他对象不是基于 MRWOD 算法的异常点。因此, 异常点集 $OS = \{x_1\}$ 。

4 实验及分析

4.1 实验准备

为了验证提出的 MRWOD 算法的有效性, 选取从相关公开网页下载的 15 个不同类型的数据集进行实验。各数据集名称、缩写、条件属性组成 (数值属性与标称属性)、样本数量、异常点数量以及对应的数据类型、所属领域如表 2 所示。同时, 使用 ROC 曲线与 AUC 值作为评价指标, 并进行了实验参数分析。

在所选取的 15 个不同类型的数据集中, 将 MRWOD 算法与 9 种具有代表性的异常检测算法进行比较。同时, 为确保比较公平, 每个比较方法在参数范围内取最优结果。具体算法名称和参数设置如下:

- (1) (2019) 一种用于检测混合类型数据中的聚类 and 散射异常点的联合学习框架 (A Joint Learning Framework for Detecting Both Clustered and Scattered Outliers in Mixed-Type Data, MIX) [57], 参数 i 从 0 调整到 9, 步长为 1。
- (2) (2018) 基于局部投影的异常检测方法 (Local Projection-based Outlier Detection, LPOD) [58], 参数 k 从 2 调整到 60, 步长为 1。
- (3) (2013) 基于信息理论的异常检测方法 (Information-Theory-based Outlier Detection, ITB) [59], 无参数方法, 无需调整参数。
- (4) (2020) 基于偏差结构分数的异常检测方法 (Variance Structural Score, VARE) [60], 参数 λ 分别选取 0.001、0.01、0.1、1、10、100, 以获得最优效果。

- (5) (2015) 基于粒计算和粗糙集异常检测的方法 (Outlier Detection based on Granular Computing and Rough set, ODGrCR) [47], 参数 w 从 1 调整到 10, 步长为 1。
- (6) (2023) 基于模糊粒异常得分的异常检测方法 (Fuzzy Granular Anomaly Score, FGAS) [56], 参数 σ 从 0 调整至 1, 步长为 0.05。
- (7) (2019) 基于虚拟异常得分的异常检测方法 (Virtual Outlier Score, VOS) [34], 参数 k 从 1 调整到 60, 步长为 1。
- (8) (2021) 基于加权邻域信息网络的异常检测方法 (Weighted Neighborhood Information Network Based Outlier Detection, WNINOD) [35], 参数从 1 调整到 10, 步长为 1。由于 WNINOD 的分数越小异常越大, 为了便于比较, 取其输出的所有初始分数的倒数作为异常分数。
- (9) (2023) 基于加权模糊粗糙密度的异常检测算法 (Weighted Fuzzy-Rough Density-based Anomaly Detection Algorithm, WFRDA) [61], 参数 σ 从 0.1 调整到 2, 步长为 0.1。

表 2 数据集相关描述
表 2 Description of the dataset

序号	数据集	缩写	条件属性数		样本数	异常点数	数据类型	所属领域
			数值	符号				
1	Chess_nowin_87_variant1	Chess87	0	36	1756	87	标称型	博弈论
2	Mushroom_p_365_variant1	Mush365	0	22	4773	365	标称型	生物学
3	Vote_republican_29_variant1	Vote	0	16	296	29	标称型	政治
4	Annthyroid	Ann	0	6	7200	534	标称型	医学
5	Cardio	Card	21	0	1831	176	数值型	医学
6	Ionosphere_b_24_variant1	Iono	34	0	249	24	数值型	物理与化学
7	Pageblocks_1_258_variant1	Page	10	0	5171	258	数值型	计算机科学
8	Yeast_ERL_5_variant1	Yeast	8	0	1141	5	数值型	生物学
9	Bands_band_42_variant1	Bands42	20	20	354	42	混合型	物理与化学
10	German_1_14_variant1	German	7	13	714	74	混合型	社会学
11	Hepatitis_2_9_variant1	Hepa	6	13	94	9	混合型	医学
12	Horse_1_12_variant1	Horse	8	19	256	12	混合型	生物学
13	Sick_sick_35_variant1	Sick35	7	22	3576	35	混合型	医学
14	CreditA_plus_42_variant1	Credit	6	9	425	42	混合型	商业
15	Heart_2_16_variant1	Heart	6	7	166	16	混合型	医学

4.2 实验结果分析

本实验分别对三种不同类型数据集上的 ROC 曲线及 AUC 值进行分析。在 ROC 曲线图中, 不同颜色的曲线表示不同的异常检测算法。其中, MRWOD 算法对应各 ROC 曲线

图中的红色曲线。如前所述，当检测算法的 ROC 曲线越接近坐标系的左上角，其检测性能越高。

如图图 1所示，MRWOD 算法在标称属性数据、数值属性数据和混合属性数据上均取得了较高的 AUC 分数，例如 Mush365 数据集、Page 数据集、Yeast 数据集、Horse 数据集，且在大多数数据集中，MRWOD 算法的曲线几乎覆盖了大部分算法的曲线。此外，MRWOD 在多个数据集上（Vote 数据集、Iono 数据集、German 数据集等）的 ROC 曲线均逼近左上角。但在部分数据集上，如 Sick35 数据集、Credit 数据集、Heart 数据集等，各算法的 ROC 曲线重叠、交叉，难以区分各算法性能。因此，本文进而选择 AUC 指标进行更为精确的算法性能比较。


表 3中展示了各属性数据集上各异常检测算法的 AUC 值对比结果，其中最佳得分用粗体展示。由表可知，MRWOD 算法在大多数数据集上表现优越，同时统计 MRWOD 在各个属性数据集获得最佳结果的次数可知，MRWOD 在标称属性数据集上（2 次）、在数值属性数据集（4 次）上以及在混合属性数据集（3 次）上获得最高排名的次数均大于其他算法。换言之，从在各个属性数据集上 MRWOD 算法均表现良好且大多优于其他算法表现而言，该算法有着不错的适应性和有效性。

表 3 各属性数据集的 AUC 对比
表 3 Experimental evaluation of AUC


数据集	MIX	LPOD	ITB	VARE	ODGrCR	FGAS	VOS	WNINOD	WFRDA	MRWOD
Chess87	0.6118	0.9140	0.9494	0.8571	0.9487	0.9519	0.9395	0.9478	0.8280	0.9480
Mush365	0.8618	0.9227	0.9086	0.7608	0.9047	0.9038	0.5001	0.8667	0.8862	0.9415
Vote	0.9954	0.1663	0.9955	0.9813	0.9954	0.9952	0.9892	0.9952	0.9948	0.9964
Ann	0.6611	0.5846	0.6279	0.5226	0.6247	0.7067	0.7712	0.6671	0.6579	0.9383
Card	0.9493	0.7318	0.9009	0.5264	0.7479	0.9527	0.9335	0.9488	0.9220	0.9584
Iono	1.0000	0.9004	0.9993	0.4559	0.9759	0.9996	0.9980	0.9965	0.9928	1.0000
Page	0.9560	0.7794	0.9010	0.7269	0.8814	0.9597	0.9809	0.9560	0.9440	0.9720
Yeast	1.0000	1.0000	0.9961	1.0000	0.9986	0.9986	0.9996	0.9982	0.9975	1.0000
Bands42	0.7531	0.7191	0.7264	0.4963	0.6960	0.7714	0.7766	0.7851	0.7213	0.7668
German	0.8914	0.9488	0.9651	0.9190	0.9795	0.9749	0.9680	0.9650	0.9841	0.9826
Hepa	0.9987	0.9699	0.9922	0.9621	0.9882	0.9974	0.9869	0.9922	0.9948	0.9987
Horse	0.8931	0.9109	0.9809	0.8689	0.9798	0.9867	0.9293	0.9658	0.9819	0.9918
Sick35	0.4329	0.8667	0.8591	0.8416	0.8698	0.8687	0.8621	0.8644	0.8679	0.8711
Credit	0.9370	0.8727	0.9910	0.6250	0.9942	0.9909	0.9343	0.9787	0.9863	0.9930
Heart	0.9738	0.9492	0.9825	0.9621	0.9850	0.9967	0.9638	0.9917	0.9950	0.9954
平均值	0.8610	0.8158	0.9184	0.7671	0.9047	0.9370	0.9022	0.9279	0.9170	0.9569

4.3 实验参数分析


在 MRWOD 算法中，邻域半径调节因子 λ 对异常检测性能具有重要影响。由于标称属性数据不受参数 λ 的影响，本节分别在数值属性数据集及混合属性数据集上进行参数敏




(a) Chess87




(b) Mush365




(c) Vote




(d) Ann




(e) Card




(f) Iono




(g) Page




(h) Yeast




(i) Bands42




(j) German




(k) Hepa




(l) Horse



(m) Sick35



(n) Credit



(o) Heart

图 1 ROC 曲线的对比实验结果

图 1 Experimental comparison results on ROC

感性分析。

首先，分析在数值属性数据集上 MRWOD 算法的参数敏感性。图 2 展示了 MRWOD 算法在数值属性数据集上 AUC 值随参数 λ 变化的曲线。在 Iono 数据集和 Yeast 数据集上，算法受参数 λ 的影响较小，随着 λ 的增加，AUC 值迅速到达了最大值，随着参数继续增大，AUC 值几乎保持不变。而在 Card 数据集和 Page 数据集上，在参数 $\lambda < 0.7$ 时，算法性能均发生了较大波动。但在 $\lambda > 0.7$ 后，MRWOD 算法的波动程度有所减弱，但 AUC 值仍持续随参数调整而发生一定波动。

综上，在整个参数取值范围内，不同数值属性数据集对参数 λ 的敏感程度存在一定差异。其中，当参数处于 $\lambda \approx 0.7$ 的右侧范围内时，MRWOD 算法参数敏感性相对较低。




图 2 数值属性数据集上 AUC 随参数 λ 的变化曲线

图 2 Variation curve of AUC with parameter λ on numerical datasets

最后，对 MRWOD 算法在混合属性数据集上的参数敏感性进行分析。如图 3 所示，在 German 数据集、Hepa 数据集、Credit 数据集和 Heart 数据集上，AUC 值在参数调整过程中近乎保持恒定，说明 MRWOD 算法在这几类混合属性数据上对参数的敏感性较低。而在 Horse 数据集和 Sick35 数据集上，AUC 值随参数调整发生相应变化，但整体波动较小，说明 MRWOD 算法在应对这两个特定混合属性数据集时，对参数有一定敏感性但有限。而在 Bands 数据集上，观察到 AUC 值随参数调整呈现出持续波动且整体下滑的态势。其波动幅度明显高于其他混合属性数据集。总结以上分析，MRWOD 算法在处理混合属性数据集时，在整个参数调整区间内对于参数调整的依赖都较小，仅在 Bands 数据集上表现出较为明显的参数敏感性。

本节对 MRWOD 算法参数敏感性的研究表明，该算法在不同数据类型上均受参数 λ 影响，但影响程度存在差异。综合来看，MRWOD 算法在混合属性数据集上的性能受参数设定影响的程度相对较弱，即参数变化导致的性能波动幅度较小。总而言之，参数 λ 的合理设置有助于提升 MRWOD 算法的异常检测性能。

5 结论

论文基于邻域粗糙集理论提出了融合多属性邻域粒信息的随机游走异常检测模型，并设计了相应算法。具体而言，算法首先构建单属性下的邻域熵及邻域关系矩阵，以此构建




图 3 混合属性数据集上 AUC 随参数 λ 的变化曲线

图 3 Variation curve of AUC with parameter λ on mixed datasets

单属性邻域对象差异度量。然后根据单属性邻域熵，计算属性序列和属性集序列。接着计算属性集下的邻域熵与邻域关系矩阵，以此得到属性集邻域对象差异度量。随后，将单属性邻域对象差异度量与属性集邻域对象差异度量进行融合，得到邻域对象差异度量，用于刻画融合多属性邻域粒信息后样本间的相异性，并进一步构建状态转移矩阵，执行马尔可夫随机游走。最终，利用迭代计算得到的平稳分布来对异常点进行检测。在 15 个公开数据集上，MRWOD 算法与 9 种主流异常检测算法进行了实验比较。从实验结果表明，MRWOD 算法适用于标称属性数据、数值属性数据与混合属性数据，且在多数数据集中取得了更优的 ROC 曲线和更高的 AUC 值。

6 参考文献

- [1] Jia Liu, Wei Huang, Hao Li, Sheng Gong Ji, Ya Jun Du, and Tian Rui Li. Slafusion: Attention fusion based on sax and lstm for dangerous driving behavior detection. *Information Sciences*, 640:119063, 2023.
- [2] Wen Gang Ma, Rui Qi Liu, Ke Hong Li, Shan Yan, and Jin Guo. An adversarial domain adaptation approach combining dual domain pairing strategy for iot intrusion detection under few-shot samples. *Information Sciences*, 629:719–745, 2023.
- [3] Ya Guo Lei, Bin Yang, Xin Wei Jiang, Feng Jia, Nai Peng Li, and Asoke K Nandi. Applications of machine learning to machine fault diagnosis: A review and roadmap. *Mechanical Systems and Signal Processing*, 138:106587, 2020.
- [4] Kang Zhou, Jing Li, Yu Ting Xiao, Jian Long Yang, Jun Cheng, Wen Liu, Wei Xin Luo, Jiang Liu, and Sheng Hua Gao. Memorizing structure-texture correspondence for image anomaly detection. *IEEE Transactions on Neural Networks and Learning Systems*, 33(6):2335–2349, 2022.

- [5] Victoria Hodge and Jim Austin. A survey of outlier detection methodologies. *Artificial Intelligence Review*, 22:85–126, 2004.
- [6] Azzedine Boukerche, Lining Zheng, and Omar Alfandi. Outlier detection: Methods, models, and classification. *ACM Computing Surveys*, 53(3), jun 2020.
- [7] F. Y. Edgeworth. Xli. on discordant observations. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 23(143):364–375, 1887.
- [8] P. J. Rousseeuw and A. M. Leroy. *Robust Regression and Outlier Detection*. John Wiley & Sons, New York, 2005.
- [9] E. M. Knorr and R. T. Ng. Algorithms for mining distance-based outliers in large datasets. In *Proceedings of the International Conference on Very Large Data Bases*, pages 392–403, Burlington, 1998. Morgan Kaufmann.
- [10] Edwin M. Knorr, Raymond T. Ng, and Vladimir Tucakov. Distance-based outliers: algorithms and applications. *The VLDB Journal*, 8(3):237–253, 2000.
- [11] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, and Jörg Sander. LOF: identifying density-based local outliers. In *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, page 93–104, New York, 2000. Association for Computing Machinery.
- [12] Zeng You He, Xiao Fei Xu, and Sheng Chun Deng. Discovering cluster-based local outliers. *Pattern Recognition Letters*, 24(9–10):1641–1650, 2003.
- [13] Zengyou He, Xiaofei Xu, and Shengchun Deng. Discovering cluster-based local outliers. *Pattern Recognition Letters*, 24(9):1641–1650, 2003.
- [14] Xingwei Yang, Longin Jan Latecki, and Dragoljub Pokrajac. Outlier detection with globally optimal exemplar-based GMM. In *Proceedings of the 2009 SIAM International Conference on Data Mining (SDM)*, pages 145–154, Philadelphia, 2009. Society for Industrial and Applied Mathematics.
- [15] Ji Zhang. Advancements of outlier detection: A survey. *EAI Endorsed Transactions on Scalable Information Systems*, 1(1), 2 2013.
- [16] Matthew Gebski and Raymond K. Wong. An efficient histogram method for outlier detection. In *Advances in Databases: Concepts, Systems and Applications*, pages 176–187, Berlin, 2007. Springer Berlin Heidelberg.
- [17] Sridhar Ramaswamy, Rajeev Rastogi, and Kyuseok Shim. Efficient algorithms for mining outliers from large data sets. *ACM Sigmod Record*, 29(2):427–438, 2000.
- [18] K. Zhang, M. Hutter, and H. Jin. A new local distance-based outlier detection approach for scattered real-world data. In *Proceedings of the Pacific-Asia Conference on Knowledge Discovery and Data Mining*, pages 813–822, Berlin, 2009. Springer.

- [19] Jian Tang, Zhixiang Chen, Ada Wai-Chee Fu, and David W. Cheung. Enhancing effectiveness of outlier detections for low density patterns. In *Advances in Knowledge Discovery and Data Mining*, pages 535–548, Berlin, 2002. Springer, Springer Berlin Heidelberg.
- [20] S. Papadimitriou, H. Kitagawa, P.B. Gibbons, and C. Faloutsos. LOCI: fast outlier detection using the local correlation integral. In *Proceedings 19th International Conference on Data Engineering (Cat. No.03CH37405)*, pages 315–326, Bangalore, 2003. IEEE.
- [21] Wen Jin, Anthony K. H. Tung, Jiawei Han, and Wei Wang. Ranking outliers using symmetric neighborhood relationship. In *Advances in Knowledge Discovery and Data Mining*, pages 577–593. Springer, 2006.
- [22] Hans-Peter Kriegel, Peer Kröger, Erich Schubert, and Arthur Zimek. LoOP: local outlier probabilities. In *Proceedings of the 18th ACM Conference on Information and Knowledge Management*, page 1649–1652, New York, 2009. Association for Computing Machinery.
- [23] Boyang Liu, Pang-Ning Tan, and Jiayu Zhou. Unsupervised anomaly detection by robust density estimation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 4101–4108, 2022.
- [24] Jinlong Huang, Qingsheng Zhu, Lijun Yang, DongDong Cheng, and Quanwang Wu. A novel outlier cluster detection algorithm without top-n parameter. *Knowledge-Based Systems*, 121:32–40, 2017.
- [25] Andrian Putina and Dario Rossi. Online anomaly detection leveraging stream-based clustering and real-time telemetry. *IEEE Transactions on Network and Service Management*, 18(1):839–854, 2020.
- [26] Xing Ping Dong, Jian Bing Shen, Ling Shao, and Luc Van Gool. Sub-markov random walk for image segmentation. *IEEE Transactions on Image Processing*, 25(2):516–527, 2015.
- [27] Ri Sheng Liu, Zhou Chen Lin, and Zhi Xun Su. Learning markov random walks for robust subspace clustering and estimation. *Neural Networks*, 59:1–15, 2014.
- [28] Xu Dong Zhao, Ran Tao, Wei Li, Heng Chao Li, Qian Du, Wen Zhi Liao, and Wilfried Philips. Joint classification of hyperspectral and lidar data using hierarchical random walk and deep cnn architecture. *IEEE Transactions on Geoscience and Remote Sensing*, 58(10):7355–7370, 2020.
- [29] Lucas Guerreiro, Filipi N Silva, and Diego R Amancio. A comparative analysis of knowledge acquisition performance in complex networks. *Information Sciences*, 555:46–57, 2021.
- [30] Jing Qiu Ding, Tommaso d’Orsi, Rajai Nasser, and David Steurer. Robust recovery for stochastic block models. In *2021 IEEE 62nd Annual Symposium on Foundations of Computer Science (FOCS)*, pages 387–394. IEEE, 2022.

- [31] Yiding Lu, Yijie Lin, Mouxing Yang, Dezhong Peng, Peng Hu, and Xi Peng. Decoupled contrastive multi-view clustering with high-order random walks. In *Proceedings of the AAAI conference on artificial intelligence*, volume 38, pages 14193–14201, 2024.
- [32] Haipeng Ding, Zhewei Wei, and Yuhang Ye. Scalable and effective graph neural networks via trainable random walk sampling. *IEEE Transactions on Knowledge and Data Engineering*, 37(2):896–909, 2024.
- [33] H.D.K. Moonesinghe and Pang-ning Tan. Outlier detection using random walks. In *2006 18th IEEE International Conference on Tools with Artificial Intelligence (ICTAI'06)*, pages 532–539, Arlington, 2006. IEEE.
- [34] Chao Wang, Zhen Liu, Hui Gao, and Yan Fu. VOS: A new outlier detection model using virtual graph. *Knowledge-Based Systems*, 185:104907, 2019.
- [35] Yu Wang and Yupeng Li. Outlier detection based on weighted neighbourhood information network for mixed-valued datasets. *Information Sciences*, 564:396–415, 2021.
- [36] Jianming Zhan, Xianfeng Huang, Yuhua Qian, and Weiping Ding. A fuzzy c-means clustering-based hybrid multivariate time series prediction framework with feature selection. *IEEE Transactions on Fuzzy Systems*, 32(8):4270–4284, 2024.
- [37] Chenglong Zhu, Xueling Ma, Pierpaolo D’Urso, Yuhua Qian, Weiping Ding, and Jianming Zhan. Long-term multivariate time-series forecasting model based on gaussian fuzzy information granules. *IEEE Transactions on Fuzzy Systems*, 32(11):6424–6438, 2024.
- [38] Ronghua Zhang, Jianming Zhan, Weiping Ding, and Witold Pedrycz. Time series forecasting based on improved multilinear trend fuzzy information granules for convolutional neural networks. *IEEE Transactions on Fuzzy Systems*, 33(3):1009–1023, 2025.
- [39] Yuan Yuan, Sihan Wang, Hongmei Chen, Chuan Luo, and Zhong Yuan. Anomaly detection based on fuzzy neighborhood rough sets. *Information Sciences*, 709:122075, 2025.
- [40] Xusheng Du, Jiong Yu, Zheng Chu, Lina Jin, and Jiaying Chen. Graph autoencoder-based unsupervised outlier detection. *Information Sciences*, 608:532–550, 2022.
- [41] Wei Wang, Yaoyao Shang, Yongzhong He, Yidong Li, and Jiqiang Liu. Botmark: Automated botnet detection with hybrid analysis of flow-based and graph-based traffic behaviors. *Information Sciences*, 511:284–296, 2020.
- [42] Alessia Albanese, Sankar K Pal, and Alfredo Petrosino. Rough sets, kernel set, and spatiotemporal outlier detection. *IEEE Transactions on Knowledge and Data Engineering*, 26(1):194–207, 2014.
- [43] Feng Jiang, Yuefei Sui, and Cungen Cao. Some issues about outlier detection in rough set theory. *Expert Systems with Applications*, 36(3, Part 1):4680–4687, 2009.

- [44] Faizah Shaari, Azuraliza Abu Bakar, and Abdul Razak Hamdan. Outlier detection based on rough sets theory. *Intelligent Data Analysis*, 13(2):191–206, 2009.
- [45] Feng Jiang, Yue Fei Sui, and Cun Gen Cao. An information entropy-based approach to outlier detection in rough sets. *Expert Systems with Applications*, 37(9):6338–6344, 2010.
- [46] Feng Jiang, Yuefei Sui, and Cungen Cao. A hybrid approach to outlier detection based on boundary region. *Pattern Recognition Letters*, 32(14):1860–1870, 2011.
- [47] Feng Jiang and Yu-Ming Chen. Outlier detection based on granular computing and rough set theory. *Applied intelligence*, 42(2):303–322, 2015.
- [48] Francisco Maciá-Pérez, Jose Vicente Berna-Martinez, Alberto Fernández Oliva, and Miguel Alfonso Abreu Ortega. Algorithm for the detection of outliers based on the theory of rough sets. *Decision Support Systems*, 75:63–75, 2015.
- [49] 袁钟. 混合数据无监督知识发现的模糊粗糙计算方法研究. PhD thesis, 西南交通大学, 2022.
- [50] Yumin Chen, Duoqian Miao, and Hongyun Zhang. Neighborhood outlier detection. *Expert Systems with Applications*, 37(12):8745–8749, 2010.
- [51] 袁钟 and 冯山. 基于邻域值差异度量的离群点检测算法. *计算机应用*, (7):1905–1909, 2018.
- [52] 袁钟, 张贤勇, and 冯山. 邻域粗糙集中基于序列的混合型属性离群点检测. *小型微型计算机系统*, (6):1317–1322, 2018.
- [53] Zhong Yuan, Xianyong Zhang, and Shan Feng. Hybrid data-driven outlier detection based on neighborhood information entropy and its developmental measures. *Expert Systems with Applications*, 112:243–257, 2018.
- [54] 胡清华 and 于达仁. *应用粗糙计算*. 科学出版社, 北京, 2012.
- [55] Qing-Hua Hu and Da-Ren Yu. Neighborhood entropy. In *2009 International Conference on Machine Learning and Cybernetics*, pages 1776–1782, Baoding, 2009.
- [56] Chang Liu, Zhong Yuan, Baiyang Chen, Hongmei Chen, and Dezhong Peng. Fuzzy granular anomaly detection using markov random walk. *Information Sciences*, 646:119400, 2023.
- [57] Hongzuo Xu, Yijie Wang, Yongjun Wang, and Zhiyue Wu. MIX: A joint learning framework for detecting both clustered and scattered outliers in mixed-type data. In *2019 IEEE International Conference on Data Mining (ICDM)*, pages 1408–1413, Beijing, 2019. IEEE.
- [58] Huawen Liu, Xuelong Li, Jiuyong Li, and Shichao Zhang. Efficient outlier detection for high-dimensional data. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 48(12):2451–2461, 2018.

- [59] Shu Wu and Shengrui Wang. Information-theoretic outlier detection for large-scale categorical data. *IEEE Transactions on Knowledge and Data Engineering*, 25(3):589–602, 2013.
- [60] Xiaojie Li, Jiancheng Lv, and Zhang Yi. Outlier detection using structural scores in a high-dimensional space. *IEEE Transactions on Cybernetics*, 50(5):2302–2310, 2020.
- [61] Zhong Yuan, Baiyang Chen, Jia Liu, Hongmei Chen, Dezhong Peng, and Peilin Li. Anomaly detection based on weighted fuzzy-rough density. *Applied Soft Computing*, 134:109995, 2023.